

Machine Learning Meets Networks

- ERRC 2026 · 150 minutos · nível intermediário
- Lorenzo Moreira Donatti · Deivis Felipe Guerreiro Fagundes
- Slides para decidir; Google Colab para experimentar.

O que uma rede nos conta?

- Sinal, tráfego, latência e perdas descrevem partes diferentes do funcionamento da rede.
- Pergunta à turma: qual decisão você tomaria se pudesse prever uma dessas variáveis?
- Nossa meta: formular, comparar e interpretar uma solução com dados reais.

Duas perguntas, duas tarefas

- Fingerprint de vários gateways → onde estava o dispositivo?
- Histórico de um enlace → qual será o RSSI na próxima hora?
- Mudam o target, o instante da decisão, o split e a unidade do erro.

O mínimo de rádio

- RSSI: potência recebida em dBm. -70 dBm é mais forte que -110 dBm.
- SNR: relação sinal/ruído em dB. Valores negativos e zero podem ser válidos.
- Gateway recebe uplinks; SF configura a transmissão LoRa.
- Obstáculos e antenas mudam o sinal. RSSI sozinho não determina distância nem PDR.

Defina o contrato

- 1. O que quero estimar?
- 2. Em que instante vou produzir a estimativa?
- 3. Que informações já existem nesse instante?
- 4. Para qual local, dispositivo ou período quero generalizar?

Um pipeline reutilizável

- Pergunta de rede → linha do dataset → X e y
- Split coerente → baseline → modelo
- Métrica com unidade → interpretação para a rede
- Prever → executar → explicar: faça um palpite antes de rodar cada bloco.

Uma coluna pode mudar de papel

- RSSI/SNR do uplink: válidos para localizar após a recepção?
- RSSI/SNR desse mesmo uplink: disponíveis antes de transmitir?
- GPS usado como rótulo: pode entrar também como feature?
- Respostas: sim; não; não. Leakage depende do contrato.

Prática 1 · Onde está o dispositivo?

- Antwerp: recorte de 12 mil pacotes e 39 gateways com coordenadas conhecidas.
- Entradas: RSSI por gateway. Saída: posição; erro geográfico em metros.
- Localização: k-NN, centroide por RSSI e Random Forest; constante como referência sem sinais.
- Abrir 01_localizacao.ipynb · passos 0 a 3.

O fingerprint como assinatura

- Vários locais podem produzir sinais semelhantes: o problema é ambíguo.
- Recepção ausente vira NaN; para os modelos, usamos um código fixo de -140.
- A identidade dos gateways importa: não fazemos média dos RSSIs entre receptores.
- Dias anteriores treinam; dias intermediários validam; dias posteriores testam.

Erro para quem decide

- Erro de localização em metros: mediana e percentil 90.
- Comparar baseline e modelo no mesmo teste.
- Sálvora: concentração espacial pode favorecer uma estimativa quase constante.
- Esse erro serviria para achar uma ferramenta numa sala? E um ativo numa região?

Pausa técnica

- Salve sua cópia do notebook.
- Se ficou para trás, consulte a versão resolvida ou o HTML.
- Próxima prática é independente: basta abrir outro notebook.

Prática 2 · Como estará o enlace?

- Goldoni et al.: um nó, 1.059 horas contínuas selecionadas pela continuidade.
- Após fechar a hora t , prever a média de RSSI de $t+1$.
- Persistência repete o último valor. Ridge combina valores passados.
- Abrir 02_forecasting.ipynb · passos 0 a 3.

A linha temporal vira uma tabela

- Hora-alvo $u=t+1$: $\text{target}=y(u)$; $\text{lag}_1=y(u-1)$; $\text{lag}_{24}=y(u-24)$.
- Histórico: $-80, -82, -81$ dBm. Persistência para a próxima hora: -81 dBm.
- Primeiros 80% treinam; últimos 20% testam.
- Observações do teste entram no histórico só depois de chegarem. Uma hora à frente por vez.

A previsão ajuda?

- RSSI em dBm; erro MAE/RMSE em dB.
- MAE: erro absoluto médio. RMSE: maior peso para grandes erros.
- O gráfico pode parecer excelente porque a série muda lentamente.
- Se Ridge perder para persistência, temos uma conclusão útil. Não ajustar pelo teste.

Clínica de armadilhas

- A. Localizar após recepção usando SNR do pacote.
- B. Prever amanhã usando chuva medida amanhã.
- C. Normalizar usando média de treino e teste juntos.
- D. Usar o RSSI que chegou às 10 h para prever às 11 h.

O instante resolve os casos

- A é válido: faz parte do fingerprint já recebido.
- B vaza futuro; uma previsão meteorológica disponível antes seria outra entrada.
- C contamina a transformação; ajuste somente no treino.
- D é válido em forecasting sequencial de um passo.

Split e overfitting

- Linhas próximas podem representar quase o mesmo local ou instante.
- Nosso teste temporal não prova localização em áreas inéditas: isso exige avaliação espacial.
- Excelente treino e teste ruim sugerem overfitting ou mudança de distribuição.
- Escolher parâmetros repetidamente pelo teste faz o teste virar parte do treinamento.

Uma boa métrica não fecha a decisão

- Mediana pode esconder a cauda: por isso olhamos P90 na localização.
- MAE pequeno não garante detectar quedas raras do enlace.
- RSSI das recepções não é taxa de entrega; faltam as transmissões não recebidas.
- Validação em outra campanha e custo dos erros seriam próximos passos.

Transfira a metodologia

- LoRa fingerprint → localização com pontos de acesso Wi-Fi.
- RSSI horário → throughput ou latência ao longo do tempo.
- Antes de trocar o algoritmo, redefina unidade, target, instante e split.
- Modelos mais complexos exigem uma razão operacional e dados adequados.

Sua resposta de saída

- Escolha uma telemetria e escreva: quero prever ____ no instante ____.
- Já conheço ____; reservarei ____ para teste.
- Meu baseline será ____; o erro será medido em ____.
- Antes de usar na rede, preciso verificar ____.

Materiais e perguntas

- Dois notebooks com aulas completas, comentários expansíveis, dados documentados e HTMLs offline.
- Fontes: López Escobar et al., Zenodo 10.5281/zenodo.13835721; Goldoni et al., Computer Networks 2022.
- Apoio: scikit-learn — Common pitfalls; Hyndman e Athanasopoulos — Forecasting: Principles and Practice.
- Perguntas: qual seria sua primeira aplicação com dados da sua rede?