Machine Learning Meets Networks

Guia prático para aplicações de aprendizado de máquina em redes sem fio e IoT

Lorenzo Moreira Donatti
Deivis Felipe Guerreiro Fagundes

Escola Regional de Redes de Computadores

2026

Duas frentes, um mesmo método

O que vamos fazer

1. Localização

Um pacote foi recebido.

Onde estava o dispositivo?

Sinais de vários gateways
↓
posição estimada

Antwerp: prática principal.
Sálvora: contraponto sobre avaliação.

2. Previsão temporal

Temos o histórico de um enlace.

Qual será o RSSI na próxima hora?

Sinais de vários instantes
↓
valor futuro estimado

Um enlace do dataset de Goldoni et al.

A proposta do minicurso

O que esperamos construir em 2h30

Partir de uma pergunta de redes, não de um algoritmo

Aprender a transformar dados de uma rede sem fio em um problema de aprendizado de máquina e avaliar se a solução faz sentido.

Ao final, esperamos que você consiga:

- Definir o que prever e quais dados estarão disponíveis naquele instante.
- Explorar os dados e separar treino e teste de acordo com a pergunta.
- Executar um exemplo no Colab e comparar o modelo com uma referência simples.
- Interpretar erros e limitações antes de concluir que o modelo é útil para a rede.

Dois estudos guiados: localização e previsão de RSSI. Não é uma formação completa em ML nem uma implantação em produção.

Por que essas perguntas interessam a redes?

Da aplicação ao dado

Localização de um ativo

Um equipamento transmite pela rede.
Queremos uma indicação de sua posição sem fornecer seu GPS ao estimador.

Serve para indicar uma região?
É preciso encontrar uma sala?

Monitoramento de um enlace

Um sensor envia telemetria regularmente.
Queremos antecipar a evolução de uma medida do sinal.

Há informação no histórico?
Ela acrescenta algo ao último valor?

Limite: prever RSSI não equivale a prever falha, perda de pacotes ou disponibilidade.

Que tipo de problema de IA é esse?

O mínimo para orientar as práticas

Abordagem	Informação para aprender	Exemplo em redes
Supervisionado	Exemplos com resposta conhecida	Sinal $\rightarrow$ posição
Não supervisionado	Procurar estrutura sem resposta-alvo fornecida	Agrupar perfis de tráfego
Por reforço	Ações, consequências e recompensas	Escolher ações de controle

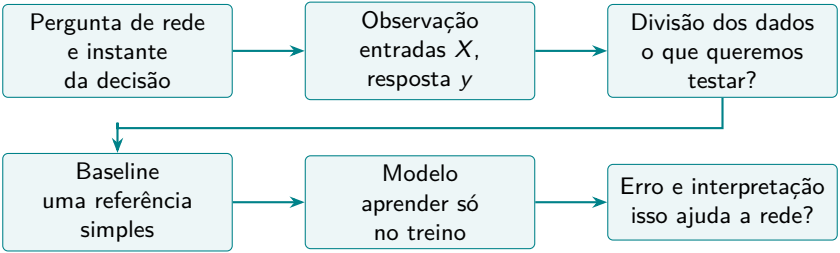
Nosso recorte

Os dois exercícios usam **regressão supervisionada**: estimar valores numéricos. No forecasting, construímos os exemplos a partir do histórico.

Se a resposta fosse uma categoria (“bom/ruim”), seria classificação.
Não vamos treinar redes neurais nem estudar todas essas abordagens.

O caminho que vamos repetir

A escolha do algoritmo vem depois da pergunta



Hoje: aprender a justificar esse caminho, não decorar algoritmos.

LoRa e LoRaWAN: do sensor à aplicação

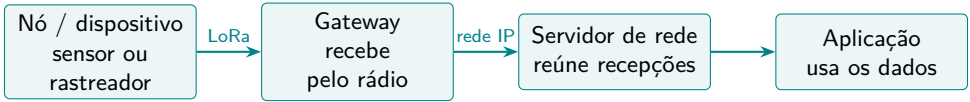
O contexto dos nossos dados

LoRa: comunicação pelo rádio

Modulação usada para transmitir pequenos volumes de dados, com foco em longo alcance e baixo consumo.

LoRaWAN: organização da rede

Protocolo que coordena a comunicação dos dispositivos com a infraestrutura. LoRa e LoRaWAN não são sinônimos.



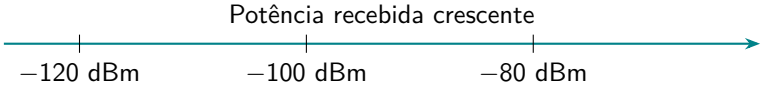
Uplink: mensagem do dispositivo para a rede. Um mesmo uplink pode chegar a vários gateways. Esquema simplificado.
Fonte: The Things Network: LoRa e LoRaWAN.

RSSI: com que potência o sinal chegou?

Received Signal Strength Indicator

A medida que aparece nos dois estudos

RSSI é um indicador da potência recebida, reportado em **dBm** nos nossos dados. dBm expressa potência em escala logarítmica, em relação a 1 mW.



−80 **dBm é mais forte que** −100 **dBm.** O sinal negativo não significa erro na medida.

- Não é uma medida direta de distância nem de taxa de entrega.
- Obstáculos, antenas e condições de propagação também afetam o valor.

Valores ilustrativos; não são faixas universais de qualidade. Fonte: The Things Network: RSSI e SNR.

SNR: quanto o sinal se destaca do ruído?

Signal-to-Noise Ratio

RSSI: potência recebida

Expressa em **dBm**.

Pergunta: com que intensidade chegou?

SNR: relação sinal/ruído

Expressa em **dB**.

Pergunta: como o sinal se compara ao ruído?

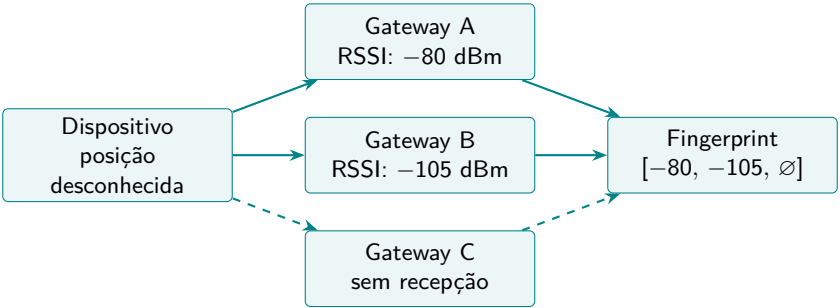
- Mesmo sinal recebido, mais ruído: menor SNR.
- SNR negativo significa sinal abaixo da potência do ruído. LoRa pode decodificar nessas condições, dentro dos limites do receptor e da configuração.
- RSSI e SNR são medições da recepção, não garantias de sucesso dos próximos pacotes.

Na prática: vamos usar RSSI; SNR ajuda a entender o contexto, mas não é uma entrada obrigatória.

Fonte: The Things Network: RSSI e SNR.

O que a rede observa?

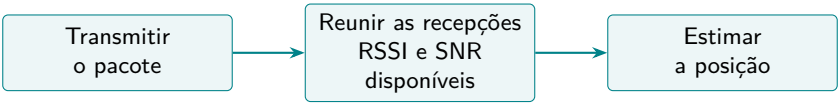
Uma transmissão, várias recepções — valores ilustrativos



RSSI: potência recebida. SNR: relação sinal/ruído.
O gateway ausente não mediu uma potência de zero dBm.

O instante define o que pode entrar

Localização depois da recepção



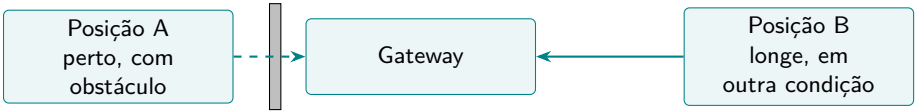
Pergunta à turma

E se quiséssemos escolher uma configuração *antes* de transmitir?

Em operação, também seria necessário definir quanto esperar pelas recepções.

Por que o sinal mais forte não resolve tudo?

RSSI não é uma régua de distância



A e B podem produzir potências semelhantes. Esquema qualitativo, não modelo de propagação.

- Ambiente e antenas também afetam a recepção.
- O padrão conjunto de vários receptores pode reduzir a ambiguidade.

De uma coleta a uma tabela supervisionada

Exemplo fictício; não são dados de Antwerp

Pacote	RSSI A	RSSI B	RSSI C	Posição GPS
1	-80	-105	ausente	(x_1, y_1)
2	-103	-82	-110	(x_2, y_2)
3	-91	ausente	-88	(x_3, y_3)

Entradas X

O fingerprint que teremos ao receber um novo pacote.

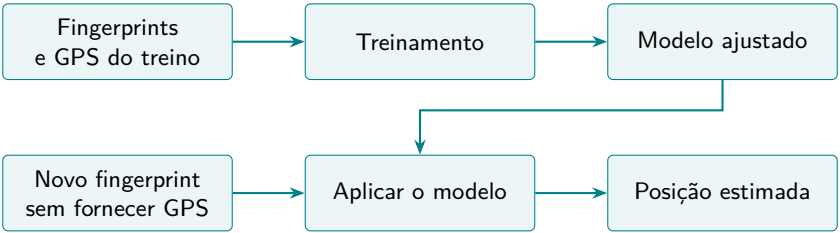
Resposta y

Coordenadas conhecidas na coleta, usadas para ensinar e avaliar.

Posição é uma resposta numérica de duas componentes: **regressão multissaída**.

Aprender não é consultar o GPS do novo pacote

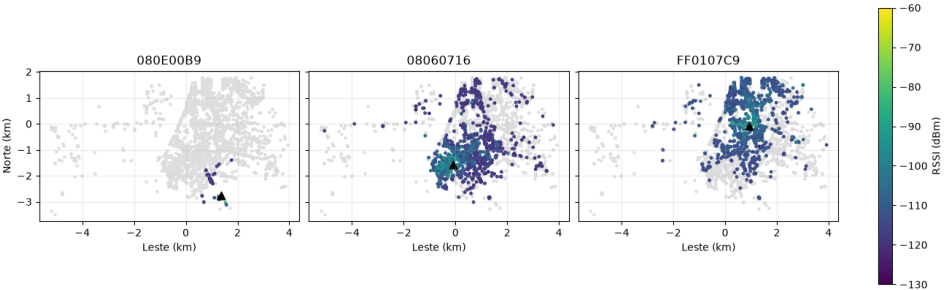
Treinamento e uso do modelo



No teste, guardamos o GPS real para conferir o erro, não para produzir a estimativa.

Antwerp: investigar a coleta

Abrir notebook 01 — seções 0 a 2



RSSI por receptor, apenas no treino. Dados: Aernouts et al., Antwerp.

- Recorte: 12 mil pacotes e 39 gateways com coordenadas conhecidas.
- Onde há observações? Que sinais distinguem essas regiões?

Três estratégias para o mesmo problema

Notebook 01 — visão geral antes do ajuste

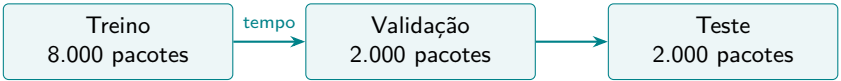
Método	Como produz a posição	Informação necessária
Centroide ponderado	Combina posições de gateways; sinal forte recebe maior peso	RSSI e coordenadas dos gateways
k-NN	Busca cinco fingerprints semelhantes e combina suas posições	Fingerprints rotulados com GPS
Random Forest	Combina regras aprendidas por várias árvores	Fingerprints rotulados com GPS

A posição mediana do treino é um **controle sem sinais**, não um sistema de localização.

$$\widehat{\mathbf{p}}_{\text{controle}} = \big(\text{mediana}(x_i), \text{mediana}(y_i)\big)_{\text{treino}}$$

Que generalização estamos avaliando?

Notebook 01 — seção 3, antes de treinar



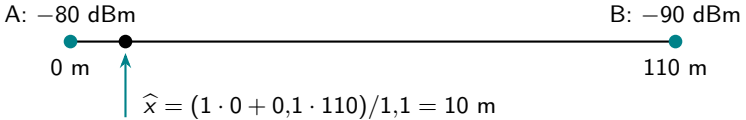
- Dias inteiros, em ordem temporal; lugares e dispositivos podem se repetir.
- Pergunta: localizar pacotes posteriores **desta rede**.
- Não é um teste em regiões inéditas nem em outra cidade.

Centroide: uma média das posições dos gateways

Referência geométrica, sem treinamento

Para cada gateway recebido: r_g é o RSSI em dBm e $\mathbf{p}_g = (x_g, y_g)$ é sua posição em coordenadas locais, em metros.

$$a_g = 10^{(r_g - r_{\max})/10}, \qquad \underbrace{\widehat{\mathbf{p}} = \frac{\sum_g a_g \, \mathbf{p}_g}{\sum_g a_g}}_{\text{média das posições, ponderada pela potência relativa}}$$



Exemplo fictício: A pesa dez vezes mais que B. $r_{\max}$ é o maior RSSI recebido.

Limite: não é trilateração nem conversão de RSSI em distância. Gateway ausente tem peso zero; com um único receptor, retorna a posição dele.

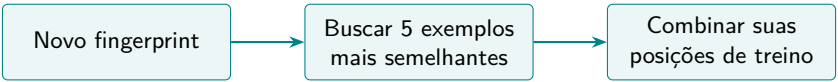
k-NN: encontrar sinais parecidos

Cinco vizinhos no espaço dos fingerprints, não no mapa

$\mathbf{r}$: novo vetor de RSSI; $\mathbf{r}_i$: vetor do treino; $\mathbf{p}_i$: posição conhecida daquele exemplo.

$$d_i = \sqrt{\sum_{g=1}^{G} (r_g - r_{ig})^2}, \qquad \widehat{\mathbf{p}} = \frac{\sum_{i \in N_5} (1/d_i)\, \mathbf{p}_i}{\sum_{i \in N_5} (1/d_i)}$$

G é o número de gateways; N_5 contém os cinco menores d_i.



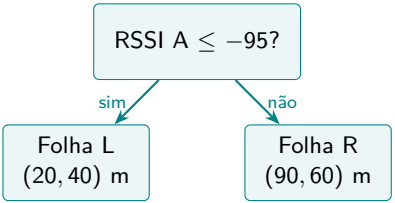
Intuição: distância de sinais 2 recebe o dobro do peso da distância 4. Se há distância zero, a implementação faz a média apenas dos vizinhos coincidentes.

Cuidado: ausência recebe o código -140 no notebook, que também afeta d_i. Fingerprints semelhantes não garantem posições próximas.

Referência: scikit-learn, KNeighborsRegressor.

Random Forest: combinar árvores de regressão

Cada árvore aprende divisões a partir dos sinais



Árvore simplificada; valores fictícios.

Na folha, a árvore retorna a média das posições dos exemplos de treino que chegaram ali.

$$\widehat{\mathbf{p}}_{\text{folha}} = \frac{1}{n_{\text{folha}}} \sum_{i \in \text{folha}} \mathbf{p}_i$$

A floresta combina T árvores ($T = 100$ no notebook):

$$\widehat{\mathbf{p}} = \frac{1}{T} \sum_{t=1}^{T} \widehat{\mathbf{p}}_t$$

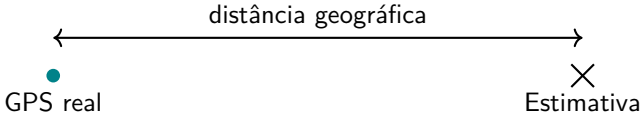
Cada árvore usa uma reamostragem do treino.

Divisões reduzem o erro quadrático dentro das folhas. A média reduz variabilidade, mas não corrige dados pouco representativos.

Referência: scikit-learn, RandomForestRegressor.

Erro em metros: o que significa?

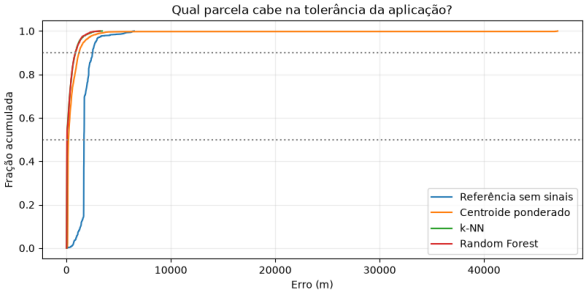
Notebook 01 — seção 5



- **Mediana:** metade dos erros é menor ou igual a esse valor.
- **P90:** 90% dos erros ficam até esse valor; não é o erro máximo.
- A tolerância depende do uso: localizar uma sala não é indicar uma região.

O resultado agregado é só o começo

Notebook 01 — avaliação de Antwerp

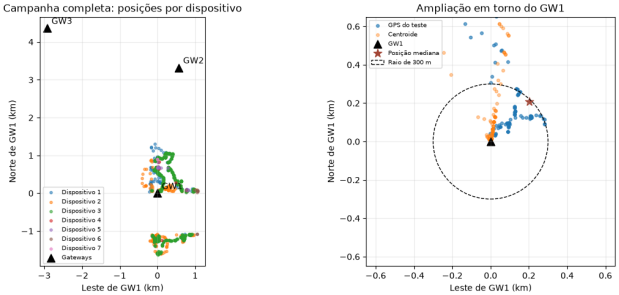


Curvas do teste temporal do tutorial; não são um benchmark dos artigos.

- Conferir a concentração espacial e os erros por condição de recepção.
- Muitos pacotes próximos não são muitas situações independentes.

Sálvora: olhar o mapa muda a interpretação

Notebook 01 — seção 6

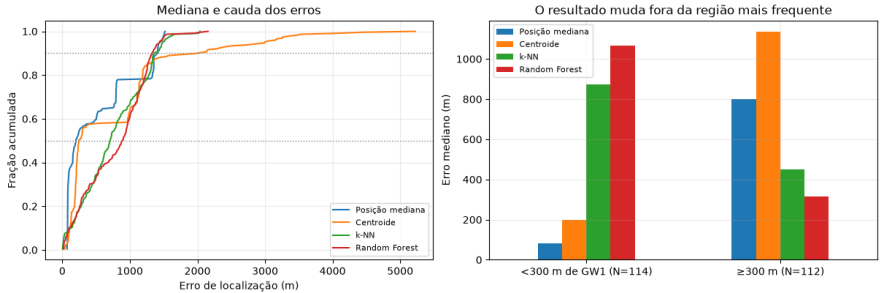


Posições das transmissões e gateways. Dados: López Escobar et al.

- Sete dispositivos móveis: cada ponto é uma medição, não um nó fixo.
- 114 dos 226 pacotes de teste ficam a menos de 300 m do GW1.

Sálvora: onde cada método erra?

Um diagnóstico posterior, sem trocar o teste



Mesmo teste, separado pela proximidade real ao GW1. O corte de 300 m é descritivo.

- O centroide é favorecido perto do GW1; a conclusão muda longe dele.
- Esses erros não devem ser comparados aos de Antwerp como um ranking.

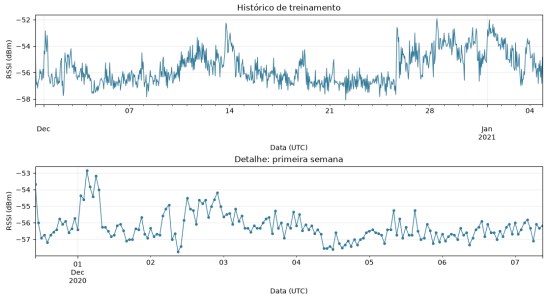
Pausa técnica

5 minutos — início no minuto 70

- Salvar a cópia do notebook.
- Conferir as saídas já salvas se alguma célula ficou para trás.
- A segunda prática é independente da primeira.

Agora, o que ainda não chegou?

Notebook 02 — seções 0 a 2



Histórico do enlace. Dados: Goldoni et al.; exploração restrita ao histórico de treino.

Situação: após fechar uma hora de observações, estimar o RSSI médio da próxima. Se a série varia lentamente, repetir o último valor já pode funcionar.

Uma série também vira uma tabela supervisionada

Notebook 02 — seção 3; exemplo fictício

Hora-alvo	RSSI anterior	RSSI de duas horas atrás	Resposta
10 h	−82	−80	−81
11 h	−81	−82	ainda desconhecida

$$X(u) = [y(u-1), y(u-2), y(u-3), y(u-6), y(u-24)] \longrightarrow y(u)$$

- Cada *lag* é uma observação passada.
- O target é um número futuro: regressão com dependência temporal.
- Não fornecer o RSSI da hora-alvo como entrada.

Respeitar a ordem dos acontecimentos

Notebook 02 — seção 4



- 1.059 horas contínuas; 24 horas iniciais formam o histórico dos lags.
- Formar lags com passado é diferente de ajustar um scaler com todos os dados.
- Testar no futuro simula a direção em que a previsão será usada.

Persistência: o que o modelo precisa superar?

Notebook 02 — seção 5; sem treinamento

Persistência

$$\widehat{y}(u) = y(u-1)$$

Repete o último valor disponível.

Sem treinamento; uma referência natural para uma série pouco variável.

Exemplo fictício

Último RSSI horário: -82 dBm.
Previsão seguinte: -82 dBm.

Se o valor real for -80 dBm:

$$|y(u) - \widehat{y}(u)| = 2 \text{ dB}.$$

$y(u)$ é o RSSI da hora-alvo; o chapéu em $\widehat{y}(u)$ indica uma estimativa.

Limite: repete o passado mais recente; não antecipa uma mudança brusca.

Ridge: aprender quanto cada lag contribui

Combinação linear com penalização dos coeficientes

Cada lag usa média μ_j e desvio σ_j do **treino**:

$$z_j(u) = \frac{y(u-k_j) - \mu_j}{\sigma_j}, \qquad \widehat{y}(u) = b + \sum_{j=1}^{5} w_j z_j(u).$$

k_j: atraso (1, 2, 3, 6 ou 24 h); b: intercepto; w_j: peso aprendido.

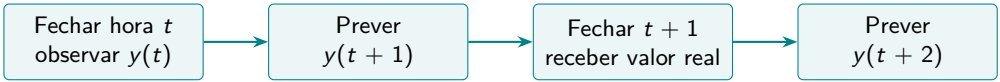
$$\min_{b,\mathbf{w}} \left[\underbrace{\sum_{u \in \text{treino}} (y(u) - \widehat{y}(u))^2}_{\text{errar pouco nos exemplos}} + \underbrace{\alpha \sum_{j=1}^{5} w_j^2}_{\text{penalizar pesos muito grandes}} \right]$$

Como ler: erro + penalização. No notebook, $\alpha = 1$ fixo.

Não é uma média ponderada: os pesos podem ser negativos e não precisam somar 1.
Referência: scikit-learn, Ridge.

Uma hora à frente, repetidamente

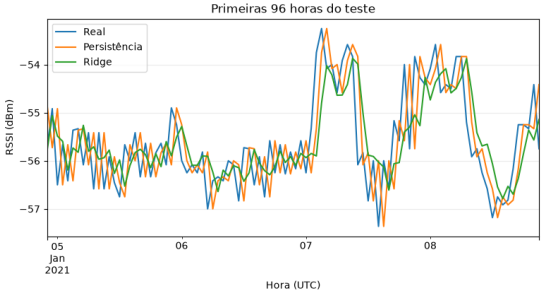
O teste não é uma previsão única de 207 horas



- Uma observação de teste pode virar histórico **depois** que chega.
- O modelo permanece fixo; não fazemos novo treinamento a cada hora.
- A média de uma hora só está disponível após o fechamento da janela.

A previsão melhora a referência?

Notebook 02 — seção 6



Teste sequencial de uma hora à frente. Dados: Goldoni et al.

- RSSI em dBm; MAE e RMSE em dB.
- Real -80 dBm, previsão -83 dBm: erro absoluto de 3 dB.
- Olhar os picos de erro, não só a média.

O que mudou entre as duas práticas?

Fechar o notebook 02 — seção 7

	Localização	Forecasting
Uma linha	Um pacote, vários gateways	Uma hora-alvo, vários lags
Resposta	Posição do transmissor	RSSI da próxima hora
Referência	Centroide; constante como controle	Persistência
Métrica	Distância em metros	Erro em dB
Limite	Não provamos generalização espacial	Não demonstramos previsão de falha

Em qual caso há vazamento?

20 minutos — discutir o instante e a separação

1. Localizar após receber, usando SNR daquele pacote.
2. Prever o RSSI de amanhã usando a temperatura *observada* amanhã.
3. Ajustar o scaler com treino e teste juntos.
4. Usar o RSSI recebido às 10 h para prever às 11 h.

Antes de responder: **essa informação estaria disponível quando a decisão fosse tomada?**

As respostas dependem do contrato

Retomar os quatro casos

- **1 e 4:** informações já disponíveis, conforme o instante definido.
- **2:** usa futuro observado; uma previsão meteorológica emitida antes seria outra informação.
- **3:** o teste participa do ajuste da transformação.

Outro cuidado

Escolher filtros, parâmetros ou a semente repetidamente pelo resultado de teste faz o teste participar do desenvolvimento.

Uma boa métrica não encerra a análise

O que faltaria para uma aplicação real?

- **Representatividade:** quais lugares, dispositivos e períodos ficaram de fora?
- **Generalização:** treino bom e teste ruim podem indicar overfitting ou mudança de condições.
- **Utilidade:** qual erro é tolerável? Quanto custa uma decisão errada?
- **Observabilidade:** só vemos recepções; não inferimos PDR sem as transmissões perdidas.

Aplicar o método a outra telemetria

15 minutos — síntese e perguntas

Exercício de fechamento

Quero estimar _____ no instante _____.

Já conheço _____. Vou reservar _____ para teste.

Minha referência será _____ e o erro será medido em _____.

Sugestões: latência, throughput, ocupação de canal ou qualidade de enlace.

Antes de escolher o algoritmo, justificar **dados, instante e avaliação**.

Referências e materiais

ERRC 2026

- Aernouts et al. *Sigfox and LoRaWAN Datasets for Fingerprint Localization in Large Urban and Rural Areas*. Data, 2018. https://doi.org/10.3390/data3020013
- Goldoni et al. *Correlation between weather and signal strength in LoRaWAN networks: An extensive dataset*. Computer Networks, 2022. https://doi.org/10.1016/j.comnet.2021.108627
- López Escobar et al. *LoRa signal quality and GPS positioning time series dataset*, 2024. https://doi.org/10.5281/zenodo.13835721
- Notebooks, dados preparados e fontes LaTeX: https://github.com/LorenzoDonatti/ML_meets_networks_ERRC2026